Machine Learning HW9

ML TAs
ntu-ml-2020spring-ta@googlegroups.com

Image clustering - outline 1/6

- 目標：分辨給定的兩張 images 是否為風景 (植物也算風景 e.g., 一片葉子)。
  - 除了 image 都是 32*32*3 的圖片，沒有任何 label
  - 只能用我們給的 data，不能使用額外的 dataset，也不能使用額外資料 train 的 model

V.S

Image clustering - data 2/6

- 請同學以 np.load() 讀入資料，valX.npy 和 valY.npy 只用來檢驗我們的訓練效果，不能用來訓練。
- trainX.npy
  - 裡面總共有 8500 張 RGB 圖片，大小都是 32*32*3
  - shape 為 (8500, 32, 32, 3)
- valX.npy
  - 請不要用來訓練
  - 裡面總共有 500 張 RGB 圖片，大小都是 32*32*3
  - shape 為 (500, 32, 32, 3)
- valY.npy
  - 請不要用來訓練
  - 對應 valX.npy 的 label
  - shape為 (500,)

Image clustering - methods 3/6

- 如果直接在原本的 image 上做 cluster，結果會很差（有很多冗餘資訊）

  → 需要更好的方式來表示原本的image

- 為了找出這個更好的方式，可以先將原始 image 做 dimension reduction，用比較少的維度來描述一張 image

  e.g., autoencoder, PCA, SVD, t-SNE.

Image clustering - requirements 4/6

1. 請實作用 **autoencoder** 將 9000 張圖片降維
2. 再利用降維過的 latent code 做分類
3. 預測 9000 筆測資是否來自相同的 dataset

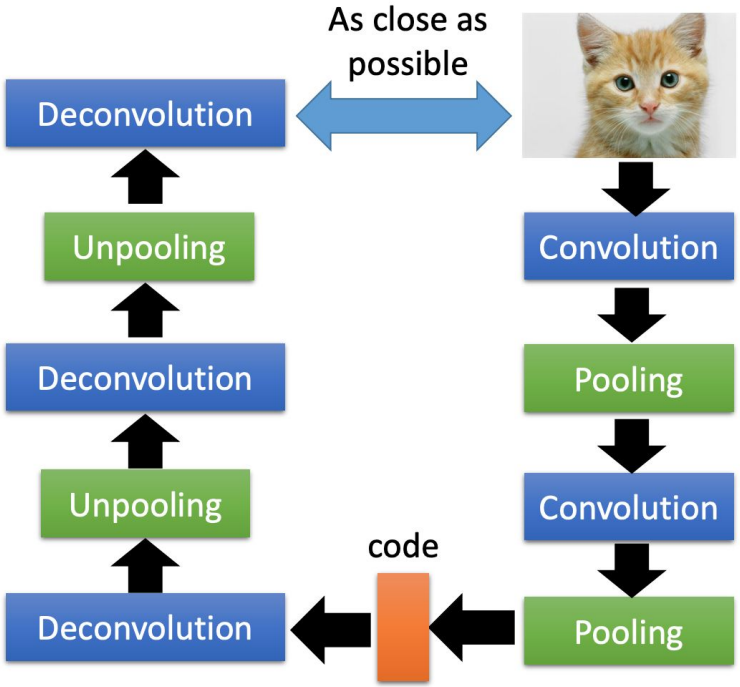

註:實作的方法需含有 autoencoder，但還是可以將其他的降維方法一起搭配使用

Image clustering - methods (cont.) 5/6

- 接著對降維過後的數據做 cluster
  - 可以試試 K-means

- 或者你可以衡量兩個降維過後的 images，他們之間的相似度 (similarity)。如果相似度大於一個設定好的 threshold，就把這兩個 images 當成同一類別
  - 算 similarity 的方法：euclidean distance, cosine similarity.....

Image clustering - methods (cont.) 6/6

- 其他可能有幫助的事：
  - 必須找個方法來衡量方法的好壞，一個直覺的方法是利用降維過後的feature 去 reconstruct 成原本的 image。如果 reconstruct 的結果越接近原本的image，可以一定程度的代表你抽出來的feature 越好
  - 對原始 image 做 data augmentation
  - 二次降維
  - 看看老師 unsupervised learning 上課內容
  - 看看網路上的 unsupervised learning 內容
    - https://stanford.edu/~shervine/teaching/cs-229/cheatsheet-unsupervised-learning
    - http://www.mit.edu/~9.54/fall14/slides/Class13.pdf

Report 1/3

- (3%) 請至少使用兩種方法 (autoencoder 架構、optimizer、data preprocessing、後續降維方法、clustering 算法等等) 來改進 baseline code 的 accuracy。
  - 記錄改進前、後的 accuracy 分別為多少。
  - 使用改進前、後的方法，分別將 val data 的降維結果 (embedding) 與他們對應的 label 畫出來。
  - 盡量詳細說明你做了哪些改進。

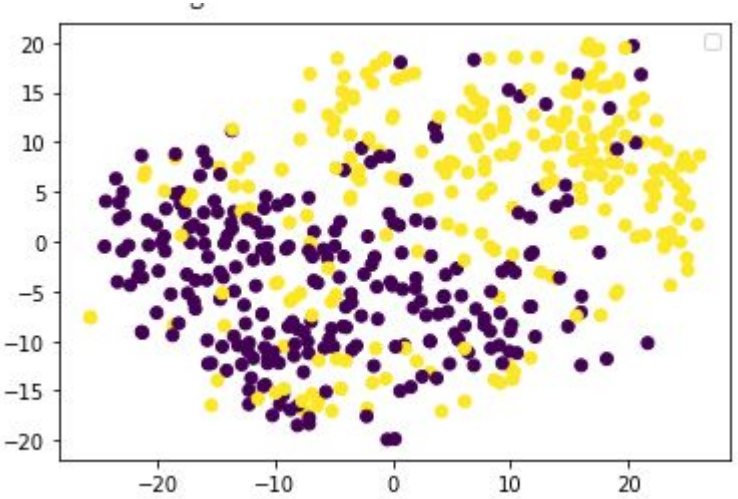

作圖範例，report 中需要畫兩張圖：
baseline model、improved model 各一張

Report 2/3

- (1%) 使用你 accuracy 最高的 autoencoder，從 trainX 中，取出 index 1, 2, 3, 6, 7, 9 這 6 張圖片。
  - 畫出他們的原圖以及 reconstruct 之後的圖片。

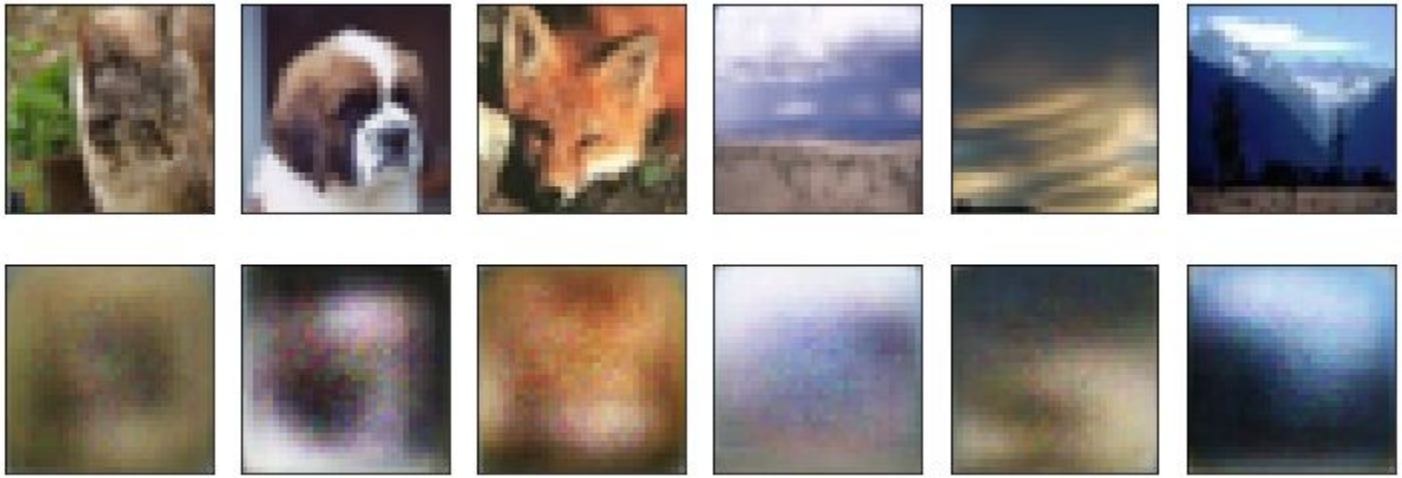

作圖範例

Report 3/3

- (2%) 在 autoencoder 的訓練過程中，至少挑選 10 個 checkpoints。
  - 請用 model 的 reconstruction error (用所有的 trainX 計算 MSE) 和 val accuracy 對那些 checkpoints 作圖。
  - 簡單說明你觀察到的現象。

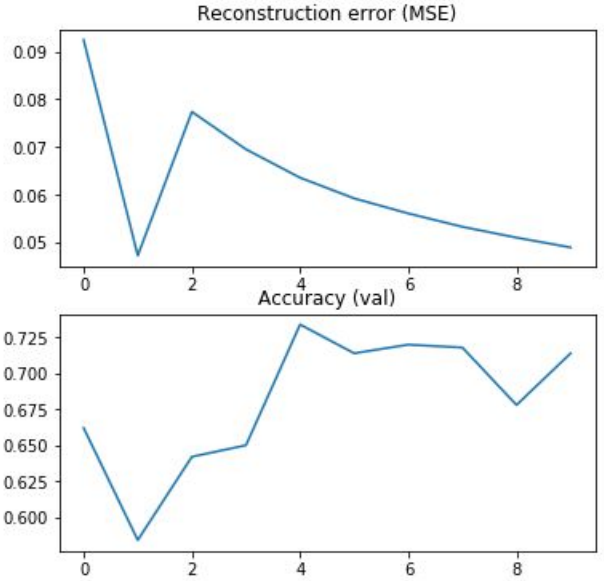

作圖範例，同學最好另外在橫軸標出單位，例如這幾個點是在第幾個 steps (或是 epochs) 儲存的 checkpoint

Submission 1/2

- report.pdf
- *.py
  - 請上傳你所有會需要用到的 .py 檔
  - ex: train_baseline.py, train_improved, model.py
- checkpoints/baseline.pth
  - 你使用在 Report Problem 1 的 baseline model
- checkpoints/improved.pth
  - 你使用在 Report Problem 1 的 improved model
- checkpoints/best.pth
  - 你在 Kaggle 上面最高分的 model，也是 Report Problem 2 的 model (可以和 checkpoints/improved.pth 一樣)

Submission 2/2

- hw9_best.sh
  - 用同學繳交上來的 checkpoints/best.pth 執行testing，也就是降維+預測的部分，要跟 kaggle上你的最高分數差不多
  - **用法: bash hw9_best.sh <trainY_npy> <checkpoint>**
- train_baseline.sh
  - 說明：訓練 Report Problem 1 的 baseline model，可以 reproduce 同學繳交上來的 checkpoints/baseline.pth
  - **用法: bash train_baseline.sh <trainX_npy> <checkpoint>**
    - trainX_npy: 助教這邊存放 trainX.npy 的路徑，請同學不要寫死
    - checkpoint: 訓練完 model 之後要存檔的路徑，請同學不要寫死
  - 範例:
    - 助教執行 bash train_bashline.sh ~/data/trainX.npy ~/chekpoints/baseline_rep.pth
- train_improved.sh
  - 用法同上，能 reproduce 同學繳交上來的 checkpoints/improved.pth

Reproduce Regulation

- 請務必在訓練過程中，隨時存取參數。
- 請同學確保你上傳的程式所產生的結果，會跟你在 Kaggle 上的結果一致，基本上誤差在 **±0.03** 之間都屬於一致，若超過以上範圍，Kaggle 將不予計分。
- Testing執行時間上限為 **10** 分鐘。
- Training執行時間上限為 **30** 分鐘。

Links

- Kaggle: https://www.kaggle.com/c/ml2020spring-hw9
- Colab: https://reurl.cc/Qdn7Mo
- Report template: https://reurl.cc/O17XO9
- 遲交表單: https://bit.ly/39d2x2m